

Optimalisasi Klasifikasi Keberhasilan UMKM sebagai Instrumen Kebijakan Pemberdayaan dan Penguatan Inklusivitas Pembiayaan



“Data Driven Solution untuk Permasalahan Nyata”

Disusun oleh:

Haliza Nur Kamila Apalwan 5025231038

Alma Khusnia 5025231063

**INSTITUT TEKNOLOGI SEPULUH NOPEMBER
SURABAYA
2026**

DAFTAR ISI

BAB I PENDAHULUAN	5
1.1 Latar Belakang	5
1.2 Rumusan Masalah	6
1.3 Tujuan	6
1.4 Batasan Masalah	6
BAB II LANDASAN TEORI.....	8
2.1 Usaha Mikro, Kecil, dan Menengah (UMKM).....	8
2.2 Algoritma <i>Machine Learning</i>	8
2.3 Metrik Evaluasi Klasifikasi	10
2.4 Stratified K-Fold Cross Validation	10
BAB III METODOLOGI.....	12
3.1 Dataset	12
3.2 Eksplorasi Data	12
3.3 Pengujian Model	15
BAB IV HASIL DAN PEMBAHASAN	18
4.1 Skenario I: Pemilihan Base Model dan Penanganan Klasifikasi Imbalance	18
4.2 Skenario II: <i>Feature Selection</i>	19
4.3 Rekomendasi Strategis dan Implementasi Solusi Berbasis Data	22
BAB V KESIMPULAN	25
5.1 Kesimpulan	25
5.2 Rekomendasi.....	25
DAFTAR PUSTAKA	27

DAFTAR TABEL

Tabel 3.1 Deskripsi Fitur Dataset.....	11
Tabel 3.2 Statistika Data.....	12
Tabel 3.3 Konfigurasi Parameter.....	15
Tabel 4.1 Perbandingan Performa Model Baseline.....	17
Tabel 4.2 Perbandingan Performa Model Optimal	17
Tabel 4.3 Nilai Koefisien Bobot Fitur pada Model <i>Logistic Regression</i> Skenario 1	20
Tabel 4.4 Hasil Evaluasi Model Final	22
Tabel 4.5 Ringkasan Rekomendasi Strategis Berbasis <i>Feature Importance</i>	22

DAFTAR GAMBAR

Gambar 3.1 Visualisasi Dataset.....	14
Gambar 3.2 Flowchart Tahapan Skenario Eksperimen Pemodelan.....	15
Gambar 4.1 <i>Correlation Map</i> Antar Fitur.....	19
Gambar 4.2 Grafik Kontribusi Fitur Berdasarkan Koefisien <i>Logistic Regression</i>	20
Gambar 4.3 Perbandingan Performa Sebelum dan Sesudah Seleksi Fitur	21
Gambar 4.4 <i>Confusion Matrix</i>	22

BAB I PENDAHULUAN

1.1 Latar Belakang

Usaha Mikro, Kecil, dan Menengah (UMKM) merupakan salah satu sektor yang memiliki peran penting dalam perekonomian Indonesia. UMKM berkontribusi dalam menciptakan lapangan kerja, meningkatkan pendapatan masyarakat, serta mendorong pertumbuhan ekonomi daerah maupun nasional [1]. Berdasarkan data Sistem Informasi Data Tunggal UMKM (SIDT-UMKM), pada Oktober 2025 terdapat sekitar 30,19 juta UMKM yang terdaftar di Indonesia, dengan sekitar 99,7% di antaranya merupakan usaha mikro, sedangkan sisanya merupakan usaha kecil dan menengah. Data tersebut menunjukkan bahwa UMKM mendominasi struktur usaha di Indonesia dan memiliki kontribusi yang signifikan terhadap perekonomian nasional. Besarnya peran tersebut menjadikan keberlangsungan dan keberhasilan UMKM sebagai aspek yang penting untuk diperhatikan. Berbagai upaya terus dilakukan untuk meningkatkan daya saing dan perkembangan UMKM di tengah persaingan bisnis yang semakin ketat.

Di balik peran pentingnya dalam perekonomian, tidak semua UMKM mampu mencapai keberhasilan yang berkelanjutan. Banyak pelaku usaha menghadapi berbagai kendala, seperti keterbatasan modal, kurangnya pengalaman bisnis, lemahnya pencatatan keuangan, serta pemanfaatan teknologi yang belum optimal [2]. Selain itu, kemampuan dalam melakukan pemasaran dan menyusun perencanaan bisnis juga menjadi faktor yang memengaruhi perkembangan usaha. Penelitian oleh *Organisation for Economic Co-operation and Development*, kemampuan manajemen, pemanfaatan teknologi digital, serta akses terhadap pengetahuan dan informasi menjadi faktor penting yang mendukung peningkatan daya saing dan kinerja UMKM [20]. Kondisi tersebut menunjukkan bahwa diperlukan analisis yang mampu mengidentifikasi faktor-faktor yang berpengaruh terhadap keberhasilan UMKM secara lebih objektif.

Perkembangan teknologi informasi dan ketersediaan data memberikan peluang untuk melakukan analisis yang lebih mendalam terhadap faktor keberhasilan UMKM. Data yang memuat karakteristik pemilik usaha, pengalaman bisnis, penggunaan internet, kualitas pencatatan keuangan, hingga kemitraan usaha dapat dimanfaatkan untuk menemukan pola yang berkaitan dengan status keberhasilan UMKM [3]. Informasi tersebut dapat menjadi dasar dalam pengambilan keputusan bagi pelaku usaha maupun pihak terkait dalam merancang strategi pengembangan UMKM. Dengan memahami faktor-faktor yang paling berpengaruh, berbagai program pendampingan dan pemberdayaan dapat dilakukan secara lebih tepat sasaran. Pemanfaatan data menjadi langkah penting dalam mendukung pertumbuhan UMKM yang berkelanjutan.

Salah satu pendekatan yang dapat digunakan untuk menganalisis data UMKM adalah *machine learning*. Metode ini mampu mempelajari pola dari data historis dan menghasilkan model prediksi yang dapat digunakan untuk mengklasifikasikan status keberhasilan suatu usaha [4]. Berbagai algoritma klasifikasi telah banyak digunakan dalam penelitian untuk membantu proses pengambilan keputusan berbasis data dengan tingkat akurasi yang baik [5]. Melalui penerapan *machine learning*, penelitian ini bertujuan untuk mengidentifikasi faktor-faktor yang memengaruhi keberhasilan UMKM serta mengevaluasi performa model

klasifikasi berdasarkan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Hasil penelitian diharapkan dapat memberikan wawasan yang bermanfaat bagi pengembangan UMKM di masa mendatang.

Salah satu pendekatan yang dapat digunakan untuk menganalisis data UMKM adalah *machine learning*. Metode ini mampu mempelajari pola dari data historis dan menghasilkan model prediksi yang dapat digunakan untuk mengklasifikasikan status keberhasilan suatu usaha [4]. Berbagai algoritma klasifikasi telah banyak digunakan dalam penelitian untuk membantu proses pengambilan keputusan berbasis data dengan tingkat akurasi yang baik [5]. Melalui penerapan *machine learning*, penelitian ini bertujuan untuk mengidentifikasi faktor-faktor yang memengaruhi keberhasilan UMKM serta mengevaluasi performa model klasifikasi berdasarkan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Hasil penelitian diharapkan dapat memberikan wawasan yang bermanfaat bagi pengembangan UMKM di masa mendatang.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Algoritma *Machine Learning* manakah yang memiliki performa paling optimal dalam mengklasifikasikan status keberhasilan UMKM?
2. Apakah pengurangan dimensi data melalui seleksi fitur dapat menghasilkan arsitektur model yang lebih efisien tanpa menurunkan akurasi prediksi?
3. Bagaimana temuan nilai matematis dari model prediktif tersebut dapat ditransformasikan menjadi bentuk rekomendasi solusi nyata bagi perkembangan ekosistem UMKM?

1.3 Tujuan

Adapun tujuan dalam penelitian ini adalah sebagai berikut.

1. Membangun, menguji, dan menentukan model klasifikasi berbasis algoritma *Machine Learning* yang paling optimal untuk memprediksi status keberhasilan UMKM.
2. Menganalisis dampak seleksi fitur terhadap efisiensi model serta konsistensi metrik evaluasi performa setelah pemangkasan atribut prediktor
3. Menghasilkan interpretasi berbasis data sebagai rekomendasi strategis yang aplikatif untuk pengembangan ekosistem UMKM

1.4 Batasan Masalah

Penelitian ini menggunakan dataset UMKM yang telah disediakan oleh panitia kompetisi sebagai sumber data utama. Analisis dilakukan berdasarkan atribut yang tersedia dalam dataset, meliputi karakteristik pemilik usaha, pengalaman bisnis, pengelolaan usaha, dan pemanfaatan teknologi. Status keberhasilan UMKM ditentukan berdasarkan label yang terdapat pada dataset dan tidak dilakukan penambahan data dari sumber eksternal. Hasil penelitian dibatasi pada identifikasi faktor-faktor yang berkaitan dengan keberhasilan UMKM berdasarkan data yang tersedia.

Model *machine learning* yang digunakan dalam penelitian ini dibatasi pada *Logistic Regression*, *Random Forest*, *Extreme Gradient Boosting (XGBoost)*, dan *Light Gradient-Boosting Machine (LightGBM)*. Evaluasi performa model dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Selain itu, penelitian ini juga menerapkan proses seleksi fitur untuk menganalisis pengaruh pengurangan atribut terhadap performa model.

Perbandingan model dilakukan berdasarkan hasil evaluasi yang diperoleh dari dataset yang digunakan.

BAB II

LANDASAN TEORI

2.1 Usaha Mikro, Kecil, dan Menengah (UMKM)

Usaha Mikro, Kecil, dan Menengah (UMKM) merupakan kegiatan usaha produktif yang dijalankan oleh individu maupun badan usaha dengan skala tertentu sesuai ketentuan yang berlaku [6]. Berdasarkan Undang-Undang Nomor 20 Tahun 2008 tentang Usaha Mikro, Kecil, dan Menengah, UMKM dibedakan menjadi usaha mikro, usaha kecil, dan usaha menengah berdasarkan kriteria kekayaan bersih atau hasil penjualan tahunan. Pengelompokan tersebut bertujuan untuk memberikan perlindungan, pembinaan, serta pemberdayaan yang sesuai dengan karakteristik masing-masing jenis usaha. Keberadaan UMKM memiliki peran penting dalam mendorong aktivitas ekonomi masyarakat di berbagai daerah. Selain itu, UMKM juga menjadi sarana bagi masyarakat untuk menciptakan lapangan kerja dan meningkatkan kesejahteraan ekonomi [1].

UMKM memiliki kontribusi yang signifikan terhadap pertumbuhan ekonomi karena mampu menyerap tenaga kerja dalam jumlah besar dan meningkatkan pemerataan pendapatan. Perkembangan UMKM dipengaruhi oleh berbagai faktor, baik yang berasal dari internal maupun eksternal usaha. Faktor internal meliputi pengalaman pemilik, kemampuan manajerial, pengelolaan keuangan, serta perencanaan bisnis [7]. Sementara itu, faktor eksternal dapat berupa akses terhadap teknologi, informasi, kemitraan usaha, dan kondisi lingkungan bisnis [8]. Oleh sebab itu, pemahaman mengenai faktor-faktor yang memengaruhi keberhasilan UMKM menjadi penting untuk mendukung pertumbuhan dan keberlanjutan usaha.

2.2 Algoritma *Machine Learning*

2.2.1 *Random Forest*

Random Forest merupakan salah satu algoritma *machine learning* berbasis *ensemble* yang digunakan untuk klasifikasi maupun prediksi suatu keputusan. Algoritma ini terdiri dari sekumpulan pohon keputusan (*decision tree*) yang dibangun menggunakan data dan fitur yang dipilih secara acak [9]. Setiap pohon keputusan menghasilkan prediksi secara independen, kemudian hasil akhir ditentukan berdasarkan suara mayoritas (*majority voting*) pada kasus klasifikasi. Penggunaan banyak pohon keputusan memungkinkan model menghasilkan prediksi yang lebih stabil dibandingkan *decision tree* tunggal. Hal tersebut membuat *Random Forest* menjadi salah satu algoritma yang banyak digunakan dalam berbagai permasalahan klasifikasi [10].

Dalam proses pelatihannya, setiap pohon keputusan melakukan pemilihan atribut terbaik berdasarkan ukuran tertentu, seperti *Gini Impurity* atau *Information Gain*, untuk memisahkan data ke dalam kelompok yang lebih homogen [11]. Penggunaan banyak pohon keputusan membuat *Random Forest* mampu mengurangi risiko *overfitting* yang sering terjadi pada *decision tree* tunggal. Selain itu, juga dapat menangani data dengan jumlah fitur yang banyak serta memberikan informasi mengenai tingkat kepentingan setiap fitur melalui *feature importance* [12]. Meskipun memiliki tingkat akurasi yang tinggi, *Random Forest* memerlukan sumber daya komputasi dan waktu pelatihan yang lebih besar dibandingkan beberapa model klasifikasi sederhana. Meskipun demikian, *Random Forest* tetap dikenal sebagai algoritma yang mampu menghasilkan performa klasifikasi yang baik pada berbagai jenis dataset.

2.2.2 Logistic Regression

Logistic Regression merupakan algoritma *machine learning* yang digunakan untuk menyelesaikan permasalahan klasifikasi biner. Algoritma ini bekerja dengan menghitung probabilitas suatu data termasuk ke dalam kelas tertentu menggunakan fungsi logistik atau *sigmoid*. Nilai probabilitas yang dihasilkan berada pada rentang 0 hingga 1 dan digunakan untuk menentukan hasil klasifikasi berdasarkan batas tertentu [13]. *Logistic Regression* banyak digunakan karena memiliki konsep yang sederhana dan mudah dipahami. Algoritma ini sering diterapkan untuk mengelompokkan data ke dalam dua kategori yang berbeda.

Logistic Regression dapat menunjukkan hubungan antara variabel input dan variabel target melalui nilai koefisien yang dihasilkan oleh model. Proses pelatihannya relatif cepat dan dapat diterapkan pada berbagai jenis data. Metode ini mampu memberikan hasil yang baik ketika pola hubungan antarvariabel dapat dipisahkan dengan jelas [14]. Namun, performanya dapat menurun ketika data memiliki hubungan yang sangat kompleks atau tidak linier. Meskipun demikian, *Logistic Regression* tetap menjadi salah satu algoritma klasifikasi yang banyak digunakan karena sederhana dan mudah diinterpretasikan.

2.2.3 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan algoritma *machine learning* yang dikembangkan dari metode *Gradient Boosting*. Algoritma ini membangun beberapa pohon keputusan secara bertahap, di mana setiap pohon baru digunakan untuk memperbaiki kesalahan dari pohon sebelumnya. Proses tersebut dilakukan secara berulang hingga menghasilkan model yang lebih akurat [9]. XGBoost menggunakan pendekatan *boosting* sehingga mampu mempelajari pola data secara lebih efektif. Algoritma ini banyak digunakan pada permasalahan klasifikasi dan prediksi.

XGBoost mampu mengolah data dengan jumlah fitur yang besar dan menghasilkan performa yang baik pada berbagai jenis dataset. Metode ini juga dilengkapi dengan mekanisme regularisasi untuk membantu mengurangi overfitting selama proses pelatihan. Selain itu, XGBoost dapat digunakan untuk mengetahui tingkat pengaruh setiap fitur melalui *feature importance* [15]. Waktu pelatihannya relatif efisien sehingga cocok digunakan pada data berukuran besar.

2.2.4 Light Gradient-Boosting Machine (LightGBM)

Light Gradient-Boosting Machine (LightGBM) merupakan algoritma *machine learning* berbasis *boosting* yang menggunakan kumpulan pohon keputusan untuk melakukan proses prediksi. Algoritma ini membangun model secara bertahap dengan memperbaiki kesalahan yang dihasilkan oleh model sebelumnya. Berbeda dengan beberapa metode *boosting* lainnya, LightGBM menggunakan pendekatan *leaf-wise tree growth* yang berfokus pada cabang dengan potensi peningkatan terbesar [16]. Pendekatan ini membantu mempercepat proses pelatihan sekaligus meningkatkan efisiensi penggunaan memori.

LightGBM mampu mengolah data berukuran besar dengan waktu pelatihan yang relatif cepat. Selain itu, LightGBM juga menyediakan informasi *feature importance* yang dapat digunakan untuk mengetahui tingkat pengaruh setiap fitur terhadap hasil prediksi [17]. Karakteristik tersebut membuat LightGBM sesuai digunakan pada berbagai jenis dataset dan permasalahan klasifikasi. LightGBM menjadi salah satu algoritma yang banyak digunakan dalam pengembangan model *machine learning*.

2.3 Metrik Evaluasi Klasifikasi

2.3.1 Accuracy

Accuracy merupakan metrik yang digunakan untuk mengukur tingkat ketepatan model dalam melakukan klasifikasi. Nilai *accuracy* menunjukkan perbandingan antara jumlah prediksi yang benar dengan seluruh data yang diuji. Semakin tinggi nilai *accuracy*, semakin baik kemampuan model dalam melakukan prediksi. Metrik ini sering digunakan untuk memberikan gambaran umum mengenai performa model klasifikasi. *Accuracy* dapat dihitung menggunakan persamaan berikut.

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Jumlah\ Total\ Sampel}$$

2.3.2 Precision

Precision merupakan metrik yang digunakan untuk mengukur tingkat ketepatan prediksi positif yang dihasilkan oleh model. Nilai *precision* menunjukkan seberapa banyak data yang diprediksi positif benar-benar termasuk ke dalam kelas positif. Metrik ini penting ketika kesalahan dalam memprediksi kelas positif perlu diminimalkan. Semakin tinggi nilai *precision*, semakin kecil jumlah prediksi positif yang salah. *Precision* dapat dihitung menggunakan persamaan berikut.

$$Precision = \frac{True\ Positives}{True\ Positives + False\ Positives}$$

2.3.3 Recall

Recall merupakan metrik yang digunakan untuk mengukur kemampuan model dalam menemukan seluruh data yang termasuk ke dalam kelas positif. Nilai *recall* menunjukkan perbandingan antara jumlah data positif yang berhasil diprediksi dengan seluruh data positif yang sebenarnya. Metrik ini penting ketika kehilangan data positif harus dihindari. Semakin tinggi nilai *recall*, semakin banyak data positif yang berhasil dikenali oleh model. *Recall* dapat dihitung menggunakan persamaan berikut.

$$Recall = \frac{True\ Positives}{True\ Positives + False\ Negatives}$$

2.3.4 F1-Score

F1-Score merupakan metrik yang menggabungkan nilai *precision* dan *recall* dalam satu ukuran evaluasi. Metrik ini digunakan untuk memberikan keseimbangan antara kemampuan model dalam menghasilkan prediksi positif yang tepat dan kemampuannya dalam menemukan seluruh data positif. Nilai *F1-Score* akan tinggi apabila *precision* dan *recall* sama-sama tinggi. Oleh karena itu, metrik ini sering digunakan pada kasus klasifikasi dengan distribusi kelas yang tidak seimbang. *F1-Score* dapat dihitung menggunakan persamaan berikut.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

2.4 Stratified K-Fold Cross Validation

Stratified K-Fold Cross Validation merupakan metode validasi yang digunakan untuk mengevaluasi performa model machine learning secara lebih stabil. Metode ini membagi dataset menjadi beberapa bagian atau fold dengan mempertahankan proporsi kelas pada setiap fold. Pada setiap iterasi, satu fold digunakan sebagai data pengujian, sedangkan fold lainnya digunakan sebagai data pelatihan [18]. Proses tersebut dilakukan secara berulang hingga seluruh fold pernah digunakan sebagai data pengujian. Pendekatan ini membantu menghasilkan evaluasi model yang lebih representatif terhadap keseluruhan dataset.

Stratified K-Fold banyak digunakan pada permasalahan klasifikasi karena mampu menjaga distribusi kelas pada setiap proses pembagian data. Hal tersebut penting terutama ketika jumlah data pada masing-masing kelas tidak seimbang [19]. Dengan mempertahankan proporsi kelas, hasil evaluasi yang diperoleh menjadi lebih konsisten dan mengurangi kemungkinan bias akibat pembagian data secara acak. Selain itu, metode ini memungkinkan seluruh data digunakan secara bergantian untuk proses pelatihan dan pengujian.

BAB III METODOLOGI

3.1 Dataset

Dataset yang digunakan merupakan data profil Usaha Mikro, Kecil, Menengah (UMKM) yang mencakup berbagai atribut penting terkait karakteristik bisnis, seperti sektor usaha, lama berdiri usaha, penggunaan *digital marketing*, modal awal, dan lainnya. Jumlah data sebanyak 250 baris yang terdiri dari 12 atribut dan 1 fitur target berupa status keberhasilan UMKM.

Tabel 3. 1 Deskripsi Fitur Dataset

Fitur	Deskripsi	Tipe Data
Age	Usia pemilik usaha	Numerik
Education	Tingkat pendidikan pemilik usaha	Ordinal (1 = SD, 2 = SMP, 3 = SMA, 4 = Sarjana, dst)
Initial_Capital	Kecukupan modal awal usaha	Biner (1 = Memadai, 0 = Tidak Memadai)
Financial_Record_Keeping	Kualitas pencatatan keuangan usaha	Biner (1 = Baik, 0 = Buruk)
Internet_Usage	Penggunaan internet dalam menjalankan usaha	Biner (1= Ya, 0 = Tidak)
Business_Plan	Ketersediaan perencanaan bisnis	Biner (1= Ada, 0 = Tidak ada)
Marketing_Effort	Tingkat usaha pemasaran yang dilakukan pemilik usaha	Skala likert (1-7)
Partnership	Kepemilikan atau keterlibatan dalam kemitraan bisnis	Biner (1= Ya, 0 = Tidak)
Parent_Business_Experience	Pengalaman bisnis yang dimiliki orang tua	Biner (1= Pernah, 0 = Tidak Pernah)
Industry_Experience	Lama pengalaman pemilik dalam industri	Numerik (tahun)
Owner_Gender	Jenis kelamin pemilik usaha	Biner (1 = Laki-laki, 0 = Perempuan)
Professional_Advice	Frekuensi konsultasi dengan profesional atau konsultan bisnis	Skala likert (1-7)
Success	Status keberhasilan usaha yang menjadi target prediksi	Biner (1= Berhasil, 0 = Tidak berhasil)

3.2 Eksplorasi Data

Pada tahap awal dilakukan pemeriksaan untuk mencari data yang memiliki nilai yang hilang (*missing value*) serta duplikat. Hasil pemeriksaan awal menunjukkan bahwa dataset ini bersih. Selanjutnya dilakukan analisis statistik deskriptif yang dapat dilihat pada tabel berikut.

Tabel 3. 2 Statistika Data

Fitur	Mean	Std_Deviation	Min	Max
Age	39.76	12.81	18.0	60.0
Education	2.88	1.41	1.0	5.0
Initial_Capital	0.52	0.5	0.0	1.0
Financial_Record_Keeping	0.49	0.5	0.0	1.0
Internet_Usage	0.44	0.5	0.0	1.0
Business_Plan	0.52	0.5	0.0	1.0
Marketing_Effort	4.0	1.99	1.0	7.0
Partnership	0.46	0.5	0.0	1.0
Parent_Business_Experience	0.44	0.5	0.0	1.0
Industry_Experience	9.76	6.16	0.0	20.0
Owner_Gender	0.56	0.5	0.0	1.0
Professional_Advice	4.14	2.08	1.0	7.0

Berdasarkan Tabel 3.2, karakteristik dan pola profil pelaku UMKM di dalam dataset dapat diidentifikasi berdasarkan aspek-aspek bisnis sebagai berikut:

a) Aspek Karakteristik Internal Pemilik Usaha:


- Age (Usia): Rata-rata usia pelaku usaha berada di angka 39.76 tahun dengan standar deviasi 12.81 tahun. Rentang usia yang bergerak dari 18 hingga 60 tahun menunjukkan bahwa subjek penelitian ini mencakup lintas generasi, mulai dari Gen Z yang baru memulai usaha hingga kelompok milenial.
- Owner_Gender (Gender): Nilai rata-rata 0.56 menunjukkan adanya dominasi tipis (56%) dari pelaku usaha laki-laki di dalam dataset ini.
- Education (Pendidikan): Rata-rata tingkat pendidikan berada di angka 2.88 (mendekati skala 3 atau lulusan SMA/ sederajat), dengan sebaran dari tingkat dasar (skala 1) hingga pendidikan tinggi/sarjana (skala 5).
- Industry_Experience (Pengalaman Industri): Pelaku UMKM memiliki pengalaman di bidangnya rata-rata selama 9.76 tahun. Angka standar deviasi sebesar 6.16 tahun merepresentasikan adanya kesenjangan pengalaman yang lebar antara pelaku usaha pemula (0 tahun) dan pelaku usaha yang sudah veteran (20 tahun).
- Parent_Business_Experience (Latar Belakang Keluarga): Sebanyak 44% pemilik UMKM memiliki orang tua yang juga berpengalaman di dunia bisnis, menandakan adanya faktor mentor atau warisan wirausaha keluarga.

b) Aspek Kesiapan Finansial dan Manajemen Keuangan:

- Initial_Capital (Kecukupan Modal Awal): Rata-rata sebesar 0.52 menunjukkan bahwa hanya 52% pelaku UMKM yang merasa mengawali bisnisnya dengan modal awal yang memadai, sedangkan 48% sisanya harus bergerak dengan keterbatasan dana.
- Financial_Record_Keeping (Pencatatan Keuangan): Baru sekitar 49% pelaku usaha yang rutin melakukan pembukuan atau pencatatan keuangan dengan baik. Hal ini mencerminkan manajemen finansial yang masih menjadi tantangan bagi sebagian besar pelaku UMKM lainnya (51%).

c) Aspek Strategi Operasional dan Adopsi Teknologi:

- **Business_Plan** (Perencanaan Bisnis): Sebanyak 52% pelaku UMKM sudah membekali diri dengan rencana bisnis yang terstruktur sebelum mengeksekusi usahanya.
 - **Internet_Usage** (Adopsi Digital): Fitur ini mencatat angka rata-rata terendah dalam aspek operasional, yaitu hanya 44%. Ini menjadi temuan kritis yang menunjukkan bahwa mayoritas pelaku UMKM (56%) di dalam dataset ini belum memanfaatkan jaringan internet/digitalisasi untuk mendukung jalannya usaha.
 - **Partnership** (Kemitraan): Keterlibatan dalam jaringan kemitraan strategis atau kolaborasi bisnis dengan pihak luar berada pada proporsi 46%.
- d) Aspek Pemasaran dan Pendampingan Usaha:
- **Marketing_Effort** (Upaya Pemasaran): Diukur dengan skala 1–7, fitur ini menghasilkan rata-rata 4.00, mengindikasikan bahwa agresivitas atau alokasi energi untuk pemasaran berada pada tingkat menengah.
 - **Professional_Advice** (Konsultasi Profesional): Nilai rata-rata mencapai 4.14 dari skala 7, menandakan bahwa pelaku UMKM di dataset ini memiliki kesadaran yang cukup tinggi untuk mencari masukan, bimbingan, atau saran dari pihak profesional/mentor demi keberlanjutan bisnis mereka




Gambar 3. 1 Visualisasi Dataset

3.3 Pengujian Model

3.3.1 Pra-pemrosesan Data

Pada tahap ini, dataset dibagi menggunakan metode *Stratified Train-Test Split* dengan rasio 80% untuk data latih dan 20% untuk data uji. Selanjutnya, fitur numerik kontinu dilakukan normalisasi menggunakan *MinMaxScaler* ke dalam rentang 0 hingga 1.

3.3.2 Skenario Pengujian



Gambar 3. 2 Flowchart Tahapan Skenario Eksperimen Pemodelan

a) Pemilihan Model dan Penanganan Data *Imbalance*

Skenario ini bertujuan untuk menentukan *base model* sekaligus arsitektur terbaik yang mampu menangani data *imbalance*. Pengujian dilakukan dengan membandingkan 4 model klasifikasi yaitu Random Forest, Logistic Regression, XGBoost, dan LightGBM ke dalam 2 kondisi:

1. Kondisi Baseline

Model dilatih dengan parameter *default* tanpa tuning.

2. Kondisi Optimal

Model XGBoost dan LightGBM diberikan parameter `scale_pos_weight` dan rumpun Scikit-Learn menggunakan `class_weight='balanced'`. Setelah itu, dilakukan *threshold tuning* pada rentang 0.1 hingga 0.9 dengan interval 0.01 untuk mencari nilai F1-Score tertinggi pada kelas minoritas.

Tabel 3. 3 Konfigurasi Parameter

Model	Kondisi Eksperimen	Hyperparameter	Nilai
Random Forest	Baseline	class_weight	None
		random_state	42
	Optimal	class_weight	balanced
		max_depth	44
		n_estimator	200
		random_state	42
Logistic Regression	Baseline	class_weight	None
		max_iter	1000
		random_state	42
	Optimal	class_weight	balanced
		max_iter	1000
		random_state	42
XGBoost	Baseline	scale_pos_weight	None
		random_state	42
	Optimal	scale_pos_weight	3.03 (188/62)
		learning_rate	0.05
		max_depth	4
		n_estimator	200
LightGBM	Baseline	scale_pos_weight	None
		random_state	42
	Optimal	scale_pos_weight	3.03 (188/62)
		learning_rate	0.05
		max_depth	4
		n_estimator	200
		random_state	42

b) Seleksi Fitur

Skenario ini bertujuan untuk mengevaluasi dampak pengurangan dimensi data (*feature reduction*) terhadap tingkat efisiensi dan performa model klasifikasi. Eksperimen ini dirancang untuk membuktikan apakah model dapat mempertahankan atau bahkan meningkatkan akurasi secara signifikan meskipun bekerja dengan jumlah fitur yang lebih sedikit, sekaligus mengidentifikasi variabel yang bersifat redundan (tidak diperlukan).

Tahapan pelaksanaan eksperimen seleksi fitur ini dirancang secara umum melalui prosedur sebagai berikut:

1. Analisis Kontribusi Atribut: Langkah awal dilakukan dengan melihat *corelation map* dan mengekstrak nilai kepentingan fitur (*feature importance* atau *coefficients weight*) dari *base model* terbaik yang terpilih pada Skenario I.
2. Eliminasi Variabel Redundan: Atribut-atribut yang mencatatkan nilai kontribusi paling minimum atau mendekati nol akan dieliminasi dari arsitektur data karena secara teoritis dianggap tidak memberikan informasi diskriminatif yang berarti bagi model.

3. Pelatihan Ulang Model: Model terbaik dari Skenario I akan dilatih kembali menggunakan subset data baru yang hanya berisi fitur-fitur dominan hasil penyaringan.
4. Validasi Model: Mengevaluasi reliabilitas model menggunakan dua instrumen utama, yaitu *Stratified 5-Fold Cross-Validation* untuk mengukur stabilitas performa model pada berbagai variasi subset data, serta menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Skenario I: Pemilihan Base Model dan Penanganan Klasifikasi Imbalance

4.1.1 Analisis Performa Model Kondisi Baseline

Pada tahap awal Eksperimen Skenario I, keempat model yaitu *Random Forest*, *Logistic Regression*, *XGBoost*, dan *LightGBM* dilatih menggunakan konfigurasi baseline, yaitu dengan mempertahankan parameter default, menggunakan nilai *threshold* standar 0.50, dan semua melatih dengan semua fitur kecuali fitur target. Berdasarkan karakteristik arsitektur algoritma yang diuji, khusus untuk model *Logistic Regression*, fitur numerik kontinu (*Age*, *Industry_Experience*, *Marketing_Effort*, *Professional_Advice*) dilakukan normalisasi menggunakan *MinMaxScaler* untuk menyamakan rentang skala data (0 hingga 1). Sebaliknya untuk model berbasis pohon, eksperimen dilakukan tanpa normalisasi. Hasil pengujian performa masing-masing model *baseline* pada data uji disajikan pada Tabel 4.1.

Tabel 4. 1 Perbandingan Performa Model Baseline

Model	Accuracy	F1-Score	Precision	Recall
Logistic Regression	0.94	0.92	0.91	0.93
Random Forest	0.80	0.66	0.74	0.64
XGBoost	0.92	0.89	0.89	0.89
LightGBM	0.88	0.83	0.85	0.81

Berdasarkan Tabel 4.1 model baseline terbaik didapatkan yaitu *Logistic Regression* daripada model berbasis *tree* dengan akurasi 0.94 dan F1-Score mencapai 0.92. Hal ini menunjukkan bahwa karakteristik data UMKM dalam penelitian ini cenderung memiliki pola pemisahan yang linear.

4.1.2 Analisis Performa Model Kondisi Optimal

Selanjutnya setelah dilakukan penyesuaian pada bobot kelas (*class_weight/scale_pos_weight*) dan pencariin *threshold*, performa masing-masing model mayoritas meningkat. Hasil pengujian dapat dilihat pada tabel berikut:

Tabel 4. 2 Perbandingan Performa Model Optimal


Model	Accuracy	F1-Score	Precision	Recall	Threshold
Logistic Regression	0.96	0.95	0.93	0.97	0.64
Random Forest	0.88	0.84	0.83	0.86	0.52
XGBoost	0.92	0.88	0.91	0.86	0.63
LightGBM	0.92	0.90	0.88	0.95	0.48

Berdasarkan Tabel 4.2, model *Logistic Regression* tetap menjadi model terbaik dibandingkan dengan model yang lain dengan akurasi meningkat menjadi 0.96, *F1-Score* meningkat menjadi 0.95, dan *Recall* sebesar 0.97. Nilai *Recall* yang tinggi menandakan bahwa setelah dilakukan pencarian *threshold* optimal, model *Logistic Regression* mampu mengenali hampir seluruh pelaku UMKM yang berhasil di dalam data uji.

Optimasi ini juga berhasil meningkatkan nilai *F1-Score* pada model *Random Forest* secara signifikan dari 0.66 menjadi 0.84 dan *Recall* dari 0.64 menjadi 0.86. Hal ini membuktikan bahwa pembatasan kedalaman struktur pohon (*max_depth* = 44) serta penyeimbangan bobot kelas mampu mereduksi bias model terhadap kelas mayoritas.

4.2 Skenario II: Feature Selection

Untuk menentukan atribut mana yang layak dipertahankan atau dieliminasi, dilakukan pendekatan berlapis yaitu melalui analisis korelasional data dan ekstraksi koefisien matematika model. Tahap awal dilakukan dengan meninjau hubungan linier mentah antar-variabel melalui matriks korelasi (*Correlation Map*) yang disajikan pada gambar berikut.




Gambar 4. 1 Correlation Map Antar Fitur

Berdasarkan gambar *Corelation Map* pada Gambar 4.1 fitur yang tidak memiliki korelasi kuat (mendekati 0) dengan fitur target (*Success*) yaitu (*Age* (0.0), *Owner_Gender* (0.0), *Education* (0.03), *Partnership* (-0.07), *Marketing_Effort* (0.07), *Parent_Business_Experience* (0.05)). Hal ini memberikan indikasi awal bahwa variansi pada data demografi pemilik, latar belakang keluarga, serta beberapa aktivitas pemasaran awal kurang memberikan kontribusi linier yang signifikan secara mandiri terhadap status keberhasilan usaha.

Namun, analisis korelasi ini terbatas pada pengujian bivariat sederhana antara satu fitur dengan fitur target. Untuk menguji tingkat kepentingan dan interaksi simultan dari seluruh fitur dalam model klasifikasi secara komprehensif, dilakukan ekstraksi nilai koefisien matematika dari model *Logistic Regression* Optimal pada Skenario I. Hasil Pemetaan bobot multivariat dari model tersebut ditunjukkan pada Tabel 4.3.

Tabel 4. 3 Nilai Koefisien Bobot Fitur pada Model Logistic Regression Skenario I

Fitur	Nilai Bobot
Business Plan	2.62
Internet Usage	2.54
Initial Capital	2.50
Financial Record Keeping	2.31
Industry Experience	1.97
Professional Advice	1.73
Marketing Effort	0.87
Parent Business Experience	0.81
Age	0.54
Partnership	-0.14
Owner Gender	0.05
Education	0.00




Gambar 4. 2 Grafik Kontribusi Fitur Berdasarkan Koefisien Logistic Regression

Berdasarkan perbandingan antara matriks korelasi sebelumnya dengan nilai koefisien pada Tabel 4.3, terdapat perubahan dinamika fitur yang menarik setelah data dimodelkan. Fitur *Age*, *Marketing_Effort*, dan *Parent_Business_Experience* menunjukkan peningkatan pengaruh (bobot menjauh dari nol) ketika dievaluasi bersama dengan variabel lain di dalam model *Logistic Regression*. Kondisi ini mengindikasikan bahwa meskipun hubungan linier mandirinya tergolong lemah, informasi dari ketiga fitur tersebut tetap memiliki kontribusi penting dalam menjaga performa prediksi model. Sebaliknya, fitur *Partnership* (-0.14), *Owner_Gender* (0.05), dan *Education* (-0.00) secara konsisten menempati posisi dengan bobot paling rendah dan sangat mendekati nilai nol. Konsistensi nilai yang mendekati nol pada pengujian bivariat maupun multivariat ini menjadi bukti kuat bahwa ketiga variabel tersebut bersifat redundan dan tidak memberikan daya pembeda yang berarti bagi sistem klasifikasi. Atas dasar pertimbangan tersebut, variabel *Partnership*,

Owner_Gender, dan *Education* diputuskan untuk dieliminasi dari arsitektur data. Langkah reduksi dimensi ini menyisakan 9 fitur utama yang kemudian digunakan untuk tahap pelatihan ulang pada Skenario II.

Setelah dilakukan pemangkasan fitur, model *Logistic Regression* dioptimalkan kembali menggunakan subset data baru yang hanya terdiri dari 9 fitur final tersebut. Hasil komparasi performa model sebelum dan sesudah proses seleksi fitur pada data uji disajikan pada Gambar 4.3.



Gambar 4. 3 Perbandingan Performa Sebelum dan Sesudah Seleksi Fitur


Fakta bahwa pergeseran nilai *threshold* optimal dari 0.64 pada Skenario I menjadi 0.66 pada Skenario II mampu mempertahankan nilai metrik secara sempurna membuktikan bahwa model memiliki tingkat *robustness* yang sangat tinggi terhadap reduksi dimensi. Proses seleksi fitur yang dilakukan telah berhasil mengeliminasi *noise* data tanpa membuang informasi penting.

Dengan mempertahankan konsistensi performa yang optimal, eliminasi terhadap fitur *Partnership*, *Owner_Gender*, dan *Education* terbukti berhasil membentuk arsitektur model yang lebih sederhana. Secara praktis, temuan ini mengindikasikan bahwa karakteristik demografi pemilik serta jejaring kemitraan formal memiliki pengaruh yang terbatas terhadap probabilitas keberhasilan UMKM dalam konteks dataset ini.

Sebagai langkah verifikasi lebih lanjut, model perlu divalidasi untuk memastikan konsistensi performa. Mengingat jumlah observasi dalam dataset yang terbatas, risiko terjadinya bias akibat pembagian data yang tidak representatif menjadi tantangan metodologis yang krusial untuk diantisipasi. Oleh karena itu, sebagai langkah verifikasi akhir, dilakukan pengujian stabilitas statistik menggunakan metode *Stratified 5-Fold Cross-Validation*. Prosedur ini bertujuan untuk menguji konsistensi performa model pada berbagai variasi subset data untuk memastikan bahwa stabilitas performa sistem bersifat objektif, reliabel, dan terbebas dari bias pemilihan data. Adapun hasil validasi tersebut disajikan dalam Tabel 4.4.

Tabel 4. 4 Hasil Evaluasi Model Final

Metrik Evaluasi	Nilai
Rata-rata F1-Macro (5 Fold CV)	0.92
Standar deviasi	0.04
<i>Accuracy</i>	0.96
<i>Precisison</i>	0.93
<i>Recall</i>	0.97
<i>F1-Score</i>	0.95



Gambar 4. 4 Confusion Matrix

Berdasarkan Tabel 4.4, konsistensi performa yang ditunjukkan oleh nilai standar deviasi yang rendah (0.04) mengonfirmasi bahwa model memiliki reliabilitas yang tinggi. Hasil *Confusion Matrix* pada data uji menunjukkan tingkat *Recall* sebesar 0.97 untuk kelas positif (UMKM Berhasil), yang mengindikasikan bahwa sistem sangat efektif dalam menangkap unit bisnis yang memiliki potensi keberhasilan. Dengan tingkat akurasi mencapai 96%, model ini telah mencapai titik optimal bagi implementasi sistem pendukung keputusan dalam memetakan profil keberhasilan UMKM.

4.3 Rekomendasi Strategis dan Implementasi Solusi Berbasis Data

Analisis model klasifikasi yang telah dilakukan memberikan *insight* bersifat *actionable* bagi pemangku kepentingan. Berdasarkan interpretasi bobot koefisien fitur, kami merumuskan strategi Prescriptive Analytics guna memastikan intervensi kebijakan yang terukur dan tepat sasaran. Berikut adalah ringkasan rekomendasi yang diusulkan:

Tabel 4. 5 Ringkasan Rekomendasi Strategis Berbasis Feature Importance

Fitur Kunci	Bobot	Rekomendasi Strategis	Fokus Intervensi
Business_Plan	2.62	Inkubasi Bisnis	Perencanaan Strategis
Internet_Usage	2.53	Akselerasi Digitalisasi	Literasi Teknologi
Initial_Capital	2.50	Automated Credit Scoring	Akses Pembiayaan
Financial_Record	2.30	Digitalisasi Pembukuan	Tata Kelola Keuangan

4.3.1 Kebijakan Program untuk Pemerintah (Dinas Koperasi dan UMKM)

Hasil analisis mengonfirmasi bahwa faktor tata kelola internal dan adaptasi teknologi memiliki korelasi yang jauh lebih signifikan terhadap kesuksesan UMKM dibandingkan profil demografi pemilik. Implementasi program kerja yang diusulkan meliputi:

a. Pendampingan Strategi dan Perencanaan Bisnis UMKM

Hasil analisis menunjukkan bahwa variabel *Business_Plan* memiliki pengaruh positif terbesar terhadap keberhasilan usaha dengan nilai bobot sebesar 2,62. Pengaruh tersebut turut didukung oleh variabel *Professional_Advice* yang memiliki bobot sebesar 1,72. Temuan ini mengindikasikan bahwa kapasitas perencanaan bisnis dan akses terhadap pendampingan profesional merupakan faktor penting dalam pengembangan UMKM. Oleh karena itu, pemerintah daerah dapat memperkuat program inkubasi usaha melalui penyediaan layanan pendampingan yang berfokus pada penyusunan rencana bisnis, perumusan strategi pemasaran, serta identifikasi risiko usaha. Pendekatan ini diharapkan dapat meningkatkan kesiapan pelaku UMKM dalam menjalankan dan mengembangkan usahanya secara berkelanjutan.

b. Transformasi Digital dan Pemasaran UMKM

Variabel *Internet_Usage* memiliki bobot sebesar 2,53, sedangkan variabel *Marketing_Effort* memiliki bobot sebesar 0,86. Hasil tersebut menunjukkan bahwa pemanfaatan teknologi digital dan aktivitas pemasaran berperan dalam meningkatkan daya saing UMKM. Berdasarkan temuan tersebut, pemerintah dapat mendorong transformasi digital melalui penyediaan pelatihan pemasaran digital, peningkatan literasi teknologi, serta perluasan akses terhadap platform perdagangan elektronik (*e-commerce*). Upaya ini diharapkan dapat membantu UMKM memperluas jangkauan pasar, meningkatkan visibilitas produk, dan memperkuat daya saing di era digital.

c. Pemberdayaan UMKM melalui Literasi dan Penguatan Tata Kelola Keuangan Usaha

Variabel *Financial_Record_Keeping* menunjukkan pengaruh yang signifikan terhadap keberhasilan usaha dengan bobot sebesar 2,30. Temuan ini mengindikasikan bahwa kemampuan pelaku usaha dalam melakukan pencatatan keuangan merupakan aspek penting dalam pengelolaan bisnis. Oleh karena itu, pemerintah dapat mengembangkan program literasi keuangan yang disertai dengan pelatihan penggunaan aplikasi pembukuan digital. Penerapan sistem pencatatan keuangan yang lebih terstruktur diharapkan dapat meningkatkan transparansi pengelolaan usaha, memudahkan pemantauan arus kas, serta mendukung akses UMKM terhadap sumber pembiayaan formal.

4.3.2 Sistem Penilaian Otomatis untuk Lembaga Keuangan

Berdasarkan hasil penelitian, model klasifikasi yang dikembangkan berpotensi dimanfaatkan sebagai dasar dalam pembangunan sistem penilaian otomatis (*data-driven scoring system*). Sistem tersebut dapat memanfaatkan delapan indikator operasional UMKM sebagai masukan untuk menghasilkan prediksi terkait potensi keberhasilan usaha. Dengan demikian, hasil prediksi model dapat digunakan sebagai informasi pendukung dalam proses pengambilan keputusan oleh lembaga keuangan. Selain itu, model menunjukkan nilai *recall* sebesar 100% pada data pengujian, yang mengindikasikan bahwa seluruh sampel UMKM yang termasuk dalam kelas positif pada dataset pengujian berhasil teridentifikasi oleh model. Temuan ini menunjukkan potensi model dalam mengurangi risiko terlewatnya UMKM yang memiliki prospek usaha yang baik.

Lembaga keuangan sering menghadapi kendala subjektivitas dalam menilai kelayakan kredit UMKM. Model yang dikembangkan berpotensi diimplementasikan sebagai Decision Support System (DSS) berbasis data-driven scoring

- a. Optimasi Pengambilan Keputusan: Sistem ini memanfaatkan indikator operasional sebagai variabel input untuk menghasilkan prediksi probabilitas keberhasilan secara real-time. Hal ini mampu mengeliminasi bias subjektif dalam penilaian kredit konvensional melalui otomasi yang terukur.
- b. Mitigasi Risiko melalui Sensitivitas Model: Dengan perolehan nilai *Recall* sebesar 0.97, model menunjukkan sensitivitas yang sangat tinggi dalam mendeteksi pelaku UMKM yang memiliki potensi keberhasilan. Hal ini secara signifikan meminimalisir *False Negative* atau risiko terlewatnya pelaku usaha yang prospektif, sehingga lembaga keuangan dapat memaksimalkan peluang pembiayaan yang produktif.
- c. Pendekatan *Human-in-the-loop*: Implementasi sistem ini dirancang sebagai alat bantu (bukan pengganti keputusan manusia). Kami merekomendasikan pendekatan *human-in-the-loop* terutama pada kasus borderline dengan probabilitas prediksi di sekitar threshold 0.66, untuk memastikan keadilan bagi pelaku usaha dengan karakteristik bisnis yang spesifik atau baru merintis.

BAB V

KESIMPULAN DAN REKOMENDASI

5.1 Kesimpulan

Berdasarkan hasil eksperimen dan analisis mendalam, penelitian ini menyimpulkan bahwa algoritma *Logistic Regression* merupakan model klasifikasi paling optimal untuk memprediksi status keberhasilan UMKM, dengan pencapaian akurasi sebesar 0.96, *F1-Score* 0.95, dan *Recall* 0.97, yang mengindikasikan bahwa data UMKM dalam penelitian ini memiliki karakteristik pemisahan linier. Proses reduksi dimensi melalui seleksi fitur telah berhasil menyederhanakan arsitektur model dari 12 menjadi 9 fitur utama tanpa menurunkan performa, sekaligus membuktikan bahwa variabel *Partnership*, *Owner_Gender*, dan *Education* bersifat redundan terhadap sistem klasifikasi. Tingkat reliabilitas dan stabilitas model telah terkonfirmasi melalui pengujian *Stratified 5-Fold Cross-Validation* yang menghasilkan rata-rata *F1-Macro* sebesar 0.92 dengan standar deviasi rendah (0,04), sehingga menunjukkan *robustness* yang tinggi serta bebas dari bias pemilihan data. Terakhir, melalui interpretasi data, ditemukan bahwa kualitas tata kelola internal serta kesiapan strategi bisnis yang mencakup perencanaan usaha yang matang, pemanfaatan teknologi digital, kecukupan modal awal, dan disiplin pencatatan keuangan menjadi prediktor paling dominan dalam menentukan keberhasilan UMKM, jauh melampaui pengaruh faktor demografi pemilik usaha

5.2 Rekomendasi

Berdasarkan temuan penelitian, berikut adalah rekomendasi strategis bagi pihak terkait:

- a. Bagi Pemerintah (Dinas Koperasi dan UMKM):
 - Mengintegrasikan program inkubasi usaha yang mensyaratkan penyusunan rencana bisnis sebagai salah satu komponen utama dalam proses pendampingan UMKM.
 - Memprioritaskan program pelatihan pemasaran digital dan adopsi e-commerce bagi pelaku usaha untuk meningkatkan pemanfaatan teknologi digital sebagai pengungkit daya saing.
 - Mendorong implementasi aplikasi pembukuan digital untuk meningkatkan kualitas tata kelola keuangan UMKM sehingga lebih tertata dan memenuhi kriteria kelayakan akses pembiayaan (bankable).
- b. Bagi Lembaga Keuangan:
 - Mengimplementasikan *Decision Support System* (DSS) dengan memanfaatkan model scoring berbasis semibilan indikator operasional sebagai alat bantu pengambilan keputusan yang lebih objektif dalam proses penilaian kelayakan kredit, sehingga dapat mengurangi subjektivitas pada metode konvensional.
 - Menggunakan model prediktif untuk meminimalkan *False Negative Rate*, sehingga lembaga keuangan dapat mengidentifikasi lebih banyak UMKM potensial yang layak dibiayai dengan tingkat presisi yang lebih baik.
 - Menerapkan model berbasis data ini sebagai alat pendukung keputusan yang tetap melibatkan verifikasi ahli, terutama pada kasus borderline dengan probabilitas prediksi di sekitar ambang batas (*threshold* 0,66), guna menjaga akurasi sekaligus keadilan bagi pelaku usaha pemula.
- c. Bagi Peneliti Selanjutnya:

- Mengembangkan riset dengan skala dataset yang lebih besar.
- Menambahkan variabel eksternal seperti kondisi makroekonomi atau tren pasar regional untuk memperkaya dimensi analisis keberhasilan UMKM.
- Mengimplementasikan Explainable AI (XAI) seperti teknik SHAP atau LIME untuk memberikan interpretasi yang lebih transparan mengenai kontribusi setiap fitur pada level individu.

DAFTAR PUSTAKA

- [1] S. Al Farisi and M. Iqbal Fasa, “PERAN UMKM (USAHA MIKRO KECIL MENENGAH) DALAM MENINGKATKAN KESEJAHTERAAN MASYARAKAT,” *Jurnal Dinamika Ekonomi Syariah*, vol. 9, no. 1, 2022, [Online]. Available: <http://ejurnal.iaipd-nganjuk.ac.id/index.php/es/index>
- [2] B. A. Herwanda and Restu Ismoyo Aji, Tantangan dan Strategi Pemasaran UMKM di Era Teknologi dan Digitalisasi. *Journal of Creative Student Research*, vol. 1, no. 6, pp. 331–344, Dec. 2023, doi: 10.55606/jcsrpolitama.v1i6.2958.
- [3] T. E., F. Kirana Putri, I. Jannah, S. P. Pandia, A. E. Seran, and A. Kaleka, “Faktor Faktor Keberhasilan Usaha UMKM Study Literatur Review,” *Aprilis Elisabeth Seran, Frischa Aprilia Kaleka INNOVATIVE: Journal Of Social Science Research*, vol. 4, pp. 13316–13329.
- [4] D. Iskandar, M. Alif Fathoni, and A. Arta Bhrata, “Smart Manufacturing Management System Memanfaatkan Big Data Dan Algoritma Machine Learning Untuk Produksi UMKM,” *Informatika Mulawarman : Jurnal Ilmiah Ilmu Komputer*, vol. 16, no. 2, p. 96, Oct. 2021, doi: 10.30872/jim.v16i2.5258.
- [5] S. Ramadhan, Z. Alamin, Miftahul Jannah, Muhammad Akbar, and Rizki Fikriyansah, “Data-driven MSME Success Prediction Using Decision Tree-Based Machine Learning Techniques,” *Journix: Journal of Informatics and Computing*, vol. 1, no. 1, pp. 1–9, Mar. 2025, doi: 10.63866/journix.v1i1.3.
- [6] Afrini Fauziah, Amanda Viola, Andita Rheinisa Ardianti, Friska Maulida, and Eustasya Griselda Daeli, “Peran UMKM terhadap Stabilitas Ekonomi Indonesia,” *Jurnal Riset Akuntansi*, vol. 2, no. 4, pp. 83–92, Oct. 2024, doi: 10.54066/jura-itb.v2i4.2593.
- [7] B. Sudiyanto, R. Basiya, and S. Widya Pratama, “PREDIKSI MASALAH KEUANGAN PADA USAHA KECIL DAN MENENGAH DENGAN MACHINE LEARNING,” *IC Tech: Majalah Ilmiah*, no. 2, 2024, [Online]. Available: <http://ejournal.stmik-wp.ac.id>
- [8] Sendy Pratama, Thara Yuniar, Wishal Putra Hendrawan, and Indah Noviyanti, “Pengaruh Strategi Inovasi Terhadap Penggunaan Teknologi Informasi Dalam Industri UMKM,” *Jurnal Bintang Manajemen*, vol. 2, no. 2, pp. 50–60, Jun. 2024, doi: 10.55606/jubima.v2i2.3046.
- [9] M. Erkamim, S. Suswadi, M. Z. Subarkah, and E. Widarti, “Komparasi Algoritme Random Forest dan XGBoosting dalam Klasifikasi Performa UMKM,” *Jurnal Sistem Informasi Bisnis*, vol. 13, no. 2, pp. 127–134, Oct. 2023, doi: 10.21456/vol13iss2pp127-134.
- [10] N. S. O’Connell, “Random Forests as Statistical Procedures: Design, Variance, and Dependence,” Feb. 2026, [Online]. Available: <http://arxiv.org/abs/2602.13104>
- [11] J. Khatib Sulaiman, F. Diba, M. Silvi Lydia, P. Sihombing, and U. Sumatera Utara, “Analisis Random Forest Menggunakan Principal Component Analysis Pada Data Berdimensi Tinggi,” *Indonesian Journal of Computer Science*.
- [12] H. A. Salman, A. Kalakech, and A. Steiti, “Random Forest Algorithm Overview,” Dec. 15, 2024, *Mesopotamian Academic Press*. doi: 10.58496/BJML/2024/007.

- [13] P. S. Reddy, D. Renu Sri, C. S. Reddy, and S. Shaik, "Sentimental Analysis using Logistic Regression," *International Journal of Engineering Research and Applications* www.ijera.com, vol. 11, pp. 36–40, 2021, doi: 10.9790/9622-1107023640.
- [14] S. Usman and F. Aziz, "Analisis Perilaku Pelanggan menggunakan Metode Ensemble Logistic Regression."
- [15] M. Wiens, A. Verone-Boyle, N. Henscheid, J. T. Podichetty, and J. Burton, "A Tutorial and Use Case Example of the eXtreme Gradient Boosting (XGBoost) Artificial Intelligence Algorithm for Drug Development Applications," *Clin. Transl. Sci.*, vol. 18, no. 3, Mar. 2025, doi: 10.1111/cts.70172.
- [16] Daffa Raihan and Imran Lubis, "OPTIMALISASI MODEL PERAMALAN PENJUALAN DENGAN PENDEKATAN ALGORITMA LIGHT GRADIENT BOOSTING MACHINE (LIGHTGBM)," *Journal Computer and Technology*, vol. 3, no. 2, pp. 137–143, Dec. 2025, doi: 10.69916/comtechno.v3i2.413.
- [17] T. H. Pramudita and M. Z. Arifin, "Hyperparameter Optimization of Light Gradient Boosting Machine for Microcirculation Detection Wearable Data," *Indonesian Journal of Innovation Studies*, vol. 27, no. 1, Jan. 2026, doi: 10.21070/ijins.v27i1.1888.
- [18] S. Widodo, H. Brawijaya, and S. Samudi, "Stratified K-fold cross validation optimization on machine learning for prediction," *Sinkron*, vol. 7, no. 4, pp. 2407–2414, Oct. 2022, doi: 10.33395/sinkron.v7i4.11792.
- [19] Rofik, J. Unjung, and B. Prasetyo, "Enhancing costumer churn prediction with stacking ensemble and stratified k-fold," *Bulletin of Electrical Engineering and Informatics*, vol. 14, no. 1, pp. 398–408, Feb. 2025, doi: 10.11591/eei.v14i1.8112.
- [20] OECD, OECD SME and Entrepreneurship Outlook 2023. Paris, France: OECD Publishing, 2023. <https://doi.org/10.1787/342b8564-en>.